SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-xxxx-xxxx

Blockchain analýza

Bakalárska práca

2026 **Postaichuk Pavlo**

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-xxxx-xxxx

Blockchain analýza

Bakalárska práca

Študijný program:	Aplikovaná informatika
Študijný odbor:	informatika
Školiace pracovisko:	Ústav informatiky a matematiky FEI STU
Školiteľ:	prof. Ing. Pavol Zajac, PhD.

2026 **Postaichuk Pavlo**

Abstrakt

Kľúčové slová

Bitcoin, Elliptic Bitcoin Dataset, analýza blockchainu, únik informácií, grafové neurónové siete

Abstract

Keywords

Bitcoin, Elliptic Bitcoin Dataset, blockchain analysis, data leakage, graph neural networks

Obsah

Úvod **7**

1 Bitcoin: platba, blok a dátový graf **8**

1.1 Bitcoinová sieť a blockchain 8
1.2 Štruktúra transakcie a model UTXO 9
1.3 Autorizácia transakcií a správa kľúčov 9
1.4 Šírenie transakcií, ťažba a potvrdenia 10
1.5 Veľkosť transakcií a poplatky 11
1.6 Grafová reprezentácia transakcií 11
1.7 Pranie špinavých peňazí a miešanie transakcií 12
1.8 Podvody a ďalšie zdroje nelegálnych výnosov 14
1.9 Verejné údaje a hranice ich interpretácie 15

2 Dátový súbor Elliptic a jeho využitie pri klasifikácii transakcií **16**

2.1 Pôvod, štruktúra a označenia transakcií 16
2.2 Rozšírenia dátového súboru Elliptic 17
2.3 Časový rozsah a transakčný graf 19
2.4 Prepojenie záznamov s verejným blockchainom 21
2.5 Príznaky transakcií a možnosti ich rozšírenia 22
2.6 Obmedzenia dátového súboru 23
2.7 Východiská vlastného riešenia 25

Záver **26**

Literatúra **27**

Zoznam obrázkov a tabuliek

Obrázok 1 Prepojenie blokov pomocou hashov hlavičiek 8
Obrázok 2 Spotrebovanie UTXO a vytvorenie nových výstupov 9
Obrázok 3 Zaradenie transakcie do aktívneho reťazca 10
Obrázok 4 Dočasné rozvetvenie blockchainu a potvrdenia 11
Obrázok 5 Grafová reprezentácia transakčných väzieb 12
Obrázok 6 Peeling chain a následné spojenie oddelených výstupov . . . 13
Obrázok 7 Spoločná transakcia typu CoinJoin 14
Obrázok 8 Investičný podvod a jeho transakčná stopa 15
Obrázok 9 Prepojenie vstupných súborov Elliptic 16
Obrázok 10 Transakčný pohľad v pôvodnom Elliptic 17
Obrázok 11 Dva prepojené pohľady v Elliptic++ 18
Obrázok 12 Podgrafy ako jednotky klasifikácie v Elliptic2 19
Obrázok 13 Orezanie transakčného okolia časovým výberom 20
Obrázok 14 Príklad transakčných podgrafov Elliptic 21
Obrázok 15 Mapovanie identifikátorov Elliptic na verejné transakcie . . . 21
Obrázok 16 Časový únik pri spoločnom referenčnom bloku 24
Obrázok 17 Prekryv adries medzi tréningom a testom 24
Obrázok 18 Príprava modelu a vyhodnotenie nového txid 25

Tabuľka 1 Základná štruktúra Elliptic 17
Tabuľka 2 Porovnanie dátových súborov Elliptic 19
Tabuľka 3 Skupiny a rozsah obnovených príznakov 22

Zoznam značiek a skratiek

AML – opatrenia proti praniu špinavých peňazí, z angl. *Anti-Money Laundering*

API – aplikačné programové rozhranie, z angl. *Application Programming Interface*

BTC – jednotka meny Bitcoin

F_1 – harmonický priemer precíznosti a úplnosti klasifikácie

GCN – grafová konvolučná sieť, z angl. *Graph Convolutional Network*

GNN – grafová neurónová sieť, z angl. *Graph Neural Network*

PR-AUC – plocha pod krivkou precíznosti a úplnosti

SHA-256 – hašovacia funkcia s 256-bitovým výstupom

`txid` – verejný identifikátor bitcoinovej transakcie

`txId` – interný anonymizovaný identifikátor záznamu Elliptic

UTXO – neminutý výstup transakcie, z angl. *Unspent Transaction Output*

vbyte – virtuálny bajt používaný na vyjadrenie veľkosti transakcie

Úvod

1 Bitcoin: platba, blok a dátový graf

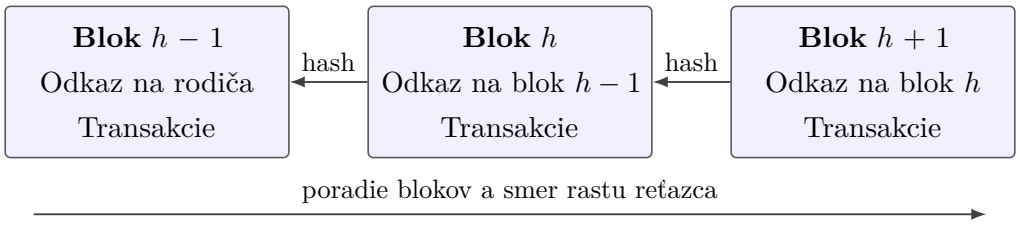
Bitcoin je decentralizovaný platobný systém, ktorý umožňuje prevod digitálnej hodnoty bez centrálneho správcu. Nakamoto [1] v pôvodnom návrhu z roku 2008 opísal spôsob, ako môže sieť účastníkov overovať platby a vytvárať spoločnú históriu transakcií. Menovou jednotkou systému je bitcoin, označovaný skratkou BTC. Jeho emisiu určujú pravidlá protokolu, ktoré obmedzujú celkové množstvo na približne 21 miliónov BTC [2].

Pre túto prácu je podstatná verejná dostupnosť transakčných záznamov a ich vzájomné prepojenie. Umožňujú rekonštruovať vzťahy medzi transakciami a odvodiť z nich údaje využiteľné pri analýze blockchainu. Význam týchto údajov však závisí od spôsobu, akým transakcie vznikajú, overujú sa a zaraďujú do blokov.

1.1 Bitcoinová sieť a blockchain

Bitcoinová sieť má usporiadanie typu peer-to-peer: jednotlivé uzly komunikujú priamo so svojimi susedmi a odovzdávajú si transakcie a bloky. Transakcia predstavuje záznam o prevode hodnoty podľa pravidiel protokolu. Blok združuje transakcie do spoločného záznamu a obsahuje hlavičku s údajmi potrebnými na jeho overenie. Úplný uzol samostatne kontroluje platnosť prijatých údajov; rozhodnutie nepreberá od banky ani od prevádzkovateľa iného uzla. Dokumentácia Bitcoin Developer Guide opisuje túto komunikáciu ako základ distribuovaného overovania [3].

Bloky sú prepojené do reťazca označovaného ako *blockchain*. Hlavička každého bloku okrem počiatočného obsahuje kryptografický odtlačok hlavičky predchádzajúceho bloku. Kryptografický odtlačok, ďalej *hash*, je hodnota pevnej dĺžky vypočítaná zo vstupných údajov. Zmena týchto údajov sa s veľmi vysokou pravdepodobnosťou prejaví zmenou hashu. Odkaz na predchádzajúci blok tak viaže nový blok na konkrétnu podobu predchádzajúcej histórie. Obrázok 1 odlišuje smer týchto odkazov od smeru rastu reťazca.



Obr. 1: Prepojenie blokov pomocou hashov ich hlavičiek. Odkazy smerujú k predchádzajúcim blokom; reťazec rastie opačným smerom. Vlastné spracovanie podľa [3].

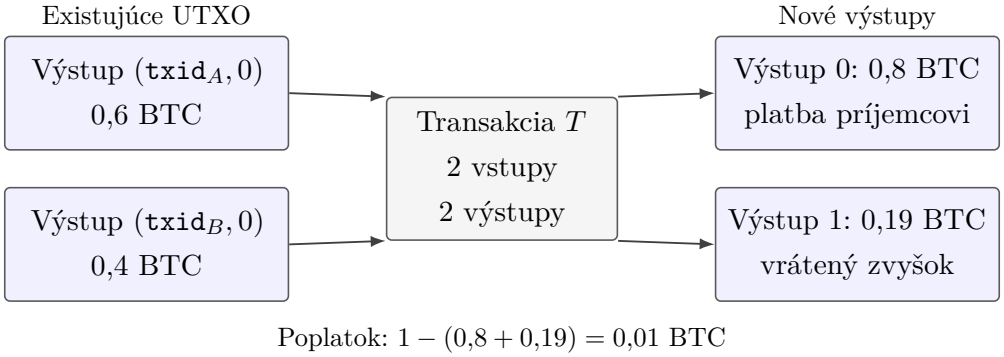
Poradie bloku v reťazci vyjadruje jeho *výška*, pričom počiatočný blok má výšku nula. Pri dočasnom rozvetvení môžu existovať viaceré bloky na rovnakej výške. Konkrétny

blok sa preto identifikuje hashom jeho hlavičky. Hlavička obsahuje aj koreň Merkleovho stromu, ktorý sa postupným hashovaním dvojíc identifikátorov transakcií vypočíta pre transakcie daného bloku. Zmena týchto identifikátorov sa premietne do hlavičky a naruší nadväzujúce hashové odkazy [3]. Odolnosť histórie voči prepisovaniu navyše závisí od dôkazu práce, ktorý je opísaný v podkapitole 1.4.

1.2 Štruktúra transakcie a model UTXO

Bežná bitcoinová transakcia[1] spotrebúva existujúce výstupy a vytvára nové. Každý výstup obsahuje hodnotu v satoshi a skript určujúci podmienky jej minutia; jeden BTC zodpovedá 100 000 000 satoshi. Výstup, ktorý zatiaľ neminula iná transakcia, sa označuje ako *UTXO* (angl. *unspent transaction output*).

Vstup nasledujúcej transakcie odkazuje na míňaný výstup identifikátorom pôvodnej transakcie `txid` a poradovým indexom `vout`. Výstup sa spotrebuje celý; prípadný zvyšok sa vracia prostredníctvom nového výstupu (*change*), ako znázorňuje obrázok 2. Poplatok predstavuje rozdiel medzi súčtom hodnôt míňaných výstupov a súčtom hodnôt nových výstupov [3].



Obr. 2: Spotrebovanie dvoch UTXO a vytvorenie dvoch nových výstupov. [3].

1.3 Autorizácia transakcií a správa kľúčov

Na platné minutie UTXO nestačí poznať jeho identifikátor. Vstup musí splniť podmienky skriptu príslušného výstupu. V bežných prípadoch ide o overenie digitálneho podpisu. *Súkromný kľúč* je tajná hodnota používaná pri podpisovaní; zodpovedajúci *verejný kľúč* umožňuje podpis overiť bez sprístupnenia súkromného kľúča. Existujú aj podmienky vyžadujúce viac podpisov alebo uplynutie určitého času. Platný podpis je teda súčasťou autorizácie, nie náhradou kontroly ostatných pravidiel transakcie [3].

[1] Výnimkou je *coinbase*, prvá transakcia bloku, ktorá nemíňa staršie výstupy a umožňuje ťažiarovi uplatniť nárok na blokovú subvenciu a poplatky [3].

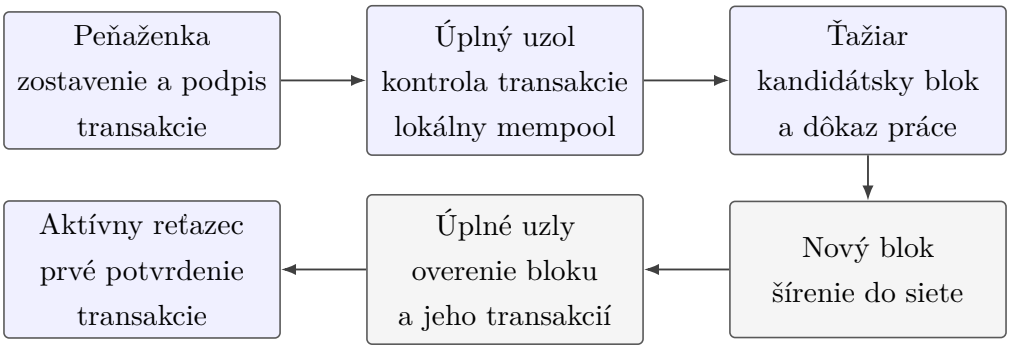
Bitcoinová *adresa* je používateľsky čitateľný, kódovaný zápis údajov, z ktorých možno pre podporovaný typ výstupu zostaviť jeho podmienku minutia. Presný význam závisí od typu adresy: môže súvisieť s verejným kľúčom alebo so skriptom. Adresu preto nemožno všeobecne stotožniť s verejným kľúčom. V samotnej transakcii sa ukladá výstupný skript; adresa je jeho bežne používanou reprezentáciou pre príslušný typ výstupu.

Peňaženka spravuje kľúče, sleduje dostupné výstupy a zostavuje transakcie. Jedna peňaženka môže používať mnoho adries, napríklad odlišnú adresu na každé prijatie platby a ďalšiu na vrátenie zvyšku. Hodnota, s ktorou môže používateľ disponovať, vyplýva z výstupov, ktorých podmienky dokáže splniť. Dokumentácia peňaženiek preto oddeľuje správu kľúčov od záznamov transakcií uložených v blockchaine [3].

1.4 Šírenie transakcií, ťažba a potvrdenia

Po zostavení a autorizácii môže peňaženka odoslať transakciu do siete. Uzol ju overí a podľa lokálnych pravidiel môže zaradiť do *mempoolu*, množiny nepotvrdených transakcií, a ďalej šíriť. Každý uzol spravuje vlastný mempool; prijatie transakcie do tejto množiny nezaručuje jej potvrdenie.

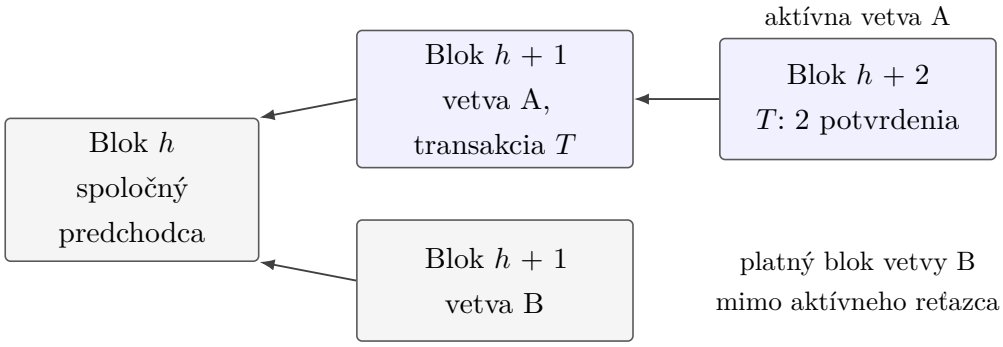
Ťažiar vyberie transakcie do kandidátskeho bloku a hľadá hlavičku, ktorej hash neprevyšuje cieľ určený náročnosťou. Tento mechanizmus sa nazýva *dôkaz práce* (angl. *proof of work*, PoW). Úplné uzly následne overia blok aj jeho transakcie, ako znázorňuje obrázok 3. Úprava náročnosti smeruje k priemernému intervalu približne desať minút medzi blokmi, nie k pevnej lehote potvrdenia transakcie [3].



Obr. 3: Priebeh úspešného zaradenia transakcie do aktívneho reťazca. Schéma nevyjadruje záruku prijatia ani pevné časové intervaly. Vlastné spracovanie podľa [3].

Spomedzi platných vetiev uzly vyberajú reťazec s najväčšou kumulatívnou prácou. Spoločné pravidlá overovania a výberu reťazca tvoria základ *konsenzu*. Transakcia získava prvé *potvrdenie* zaradením do aktívneho reťazca a každým nadväzujúcim blokom ďalšie. Pri zmene aktívnej vetvy, nazývanej *reorganizácia*, môže potvrdenie stratiť

(obrázok 4). Viac potvrdení sťažuje nahradenie histórie, neposkytuje však absolútnu záruku nezvratnosti [1, 3].



Obr. 4: Dočasné rozvetvenie blockchainu. V príklade majú bloky rovnakú prácu, preto vetva A predstavuje väčšiu kumulatívnu prácu než vetva B. Šípky označujú odkazy na predchádzajúce bloky. Vlastné spracovanie podľa [3].

1.5 Veľkosť transakcií a poplatky

Pre výpočet poplatku f bežnej transakcie platí

$$f = \sum_{i=1}^{n} v_i^{\text{in}} - \sum_{j=1}^{m} v_j^{\text{out}}, \tag{1}$$

kde v_i^{in} označujú hodnoty míňaných výstupov a v_j^{out} hodnoty nových výstupov.

Obmedzená kapacita bloku ovplyvňuje výber transakcií aj ich poplatky. Pri mechanizme *SegWit* (angl. *Segregated Witness*) sa údaje svedkov potrebné na overenie minutia oddeľujú od základnej serializácie, z ktorej sa počíta `txid`. BIP 141 [4] rozlišuje veľkosť v bajtoch, váhu W a virtuálnu veľkosť V:

$$W = 3B_{\text{base}} + B_{\text{total}}, \qquad V = \left\lceil \frac{W}{4} \right\rceil, \tag{2}$$

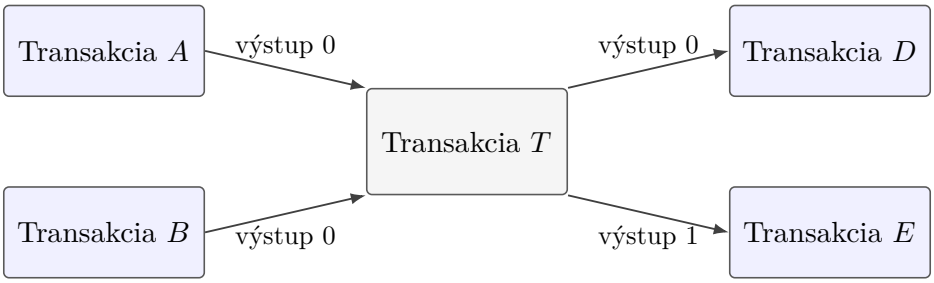
kde B_{base} je veľkosť serializácie bez údajov svedkov a B_{total} veľkosť vrátane nich. Váha sa udáva vo váhových jednotkách (WU), virtuálna veľkosť vo virtuálnych bajtoch (vB). Limit váhy bloku je 4 000 000 WU.

Poplatok f z rovnice (1) treba odlišovať od poplatkovej sadzby $r = f/V$, vyjadrenej v satoshi na virtuálny bajt (sat/vB). Ťažiari môžu uprednostňovať transakcie s vyššou sadzbou, pričom rešpektujú závislosti od nepotvrdených predchodcov.

1.6 Grafová reprezentácia transakcií

Odkazy vstupov na staršie výstupy umožňujú zostaviť smerovaný graf $G = (V, E)$. V transakčnom grafe každý vrchol $T_i \in V$ predstavuje jednu transakciu. Hrana $(T_i, T_j) \in E$

existuje vtedy, keď transakcia T_j míňa aspoň jeden výstup transakcie T_i. Jej smer vyjadruje závislosť minutia, od vytvorenia výstupu k jeho spotrebovaniu. Takto vytvorený graf platných transakcií je acyklický: transakcia nemôže priamo ani nepriamo minúť svoj vlastný budúci výstup.



Obr. 5: Transakčný graf nadväzujúci na príklad UTXO. Transakcia T míňa výstupy transakcií A a B; jej nové výstupy neskôr míňajú transakcie D a E. Každá šípka smeruje od rodičovskej transakcie k potomkovi.

Obrázok 5 ukazuje prechod od výstupov z obrázka 2 k vrcholom grafu. Ak jedna transakcia míňa viac výstupov toho istého predchodcu, jednoduchý graf ich zlúči do jednej hrany. Detailnejšia reprezentácia môže zachovať jednotlivé odkazy aj ich hodnoty. Voľba reprezentácie tak ovplyvňuje napríklad počet hrán a interpretáciu stupňa vrcholu. Rodičovská a potomkovská transakcia pritom môžu byť súčasťou toho istého bloku; závislosť nevyžaduje rozdielnu výšku blokov.

Transakčný graf sa odlišuje od grafu adries, v ktorom vrcholy predstavujú adresy. Pri viacerých vstupoch a výstupoch protokol neurčuje, ktorá časť konkrétneho vstupu financuje konkrétny výstup. Prevod transakcie na vážené hrany medzi adresami preto vyžaduje zvolené pravidlo priradenia hodnoty.

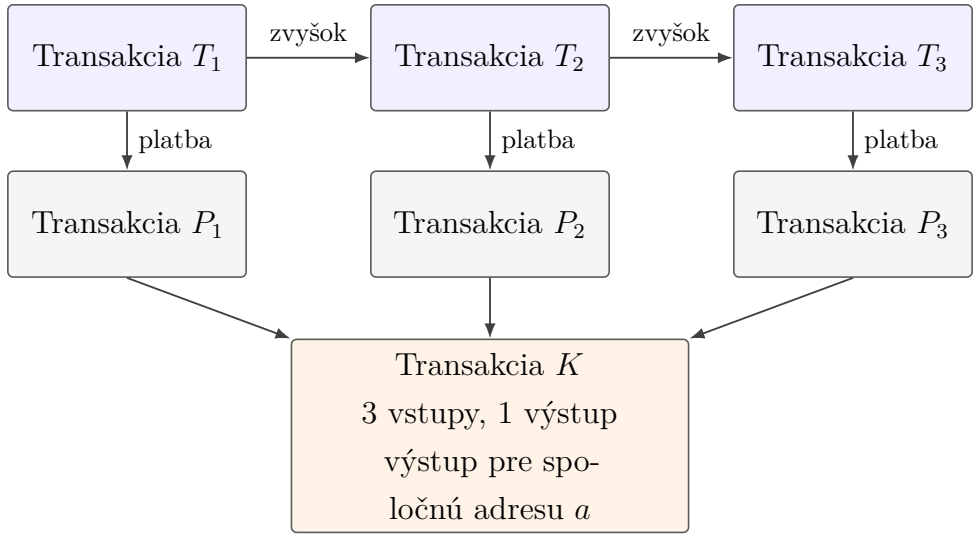
1.7 Pranie špinavých peňazí a miešanie transakcií

Pri praní špinavých peňazí páchatelia zakrývajú nezákonný pôvod výnosov a ich väzbu na trestnú činnosť. V prostredí Bitcoinu môžu prevádzať už získané bitcoiny alebo doň vnášať výnosy pôvodne získané v inej forme. Europol [5] opisuje využívanie sprostredkovateľských služieb aj profesionálnych sietí, ktoré pre iných páchateľov zabezpečujú presuny a výmenu takýchto prostriedkov. Pre grafovú analýzu je podstatné, ako tieto postupy menia pozorovateľné transakčné väzby.

Páchatelia môžu rozdeľovať prostriedky medzi viacero adries, spájať ich do spoločných transakcií a presúvať cez viaceré služby. Organizácia FATF (angl. *Financial Action Task Force*) medzi rizikové vzorce zaraďuje rýchle nadväzujúce prevody či zhromažďovanie platieb z viacerých zdrojov bez zrejmého ekonomického dôvodu [6].

Jedným z pozorovateľných vzorcov je *peeling chain*, teda reťazec transakcií, v ktorom sa postupne oddeľujú platby a vracaný zvyšok sa používa v ďalšej transakcii. Kappos a spoluautori [7] využívajú tieto väzby na sledovanie prostriedkov a overovanie zoskupenia adries. Obrázok 6 dopĺňa tento vzorec o následné spojenie oddelených častí v transakcii K, ktorá vytvorí výstup pre spoločnú adresu a. V modelovom scenári páchateľ ovláda zobrazené prevody a ďalšími transakciami sa pokúša sťažiť sledovanie nelegálnych výnosov. Odkazy medzi míňanými výstupmi pritom zostávajú verejné.

Modelový scenár: rozdelenie a opätovné spojenie nelegálnych výnosov

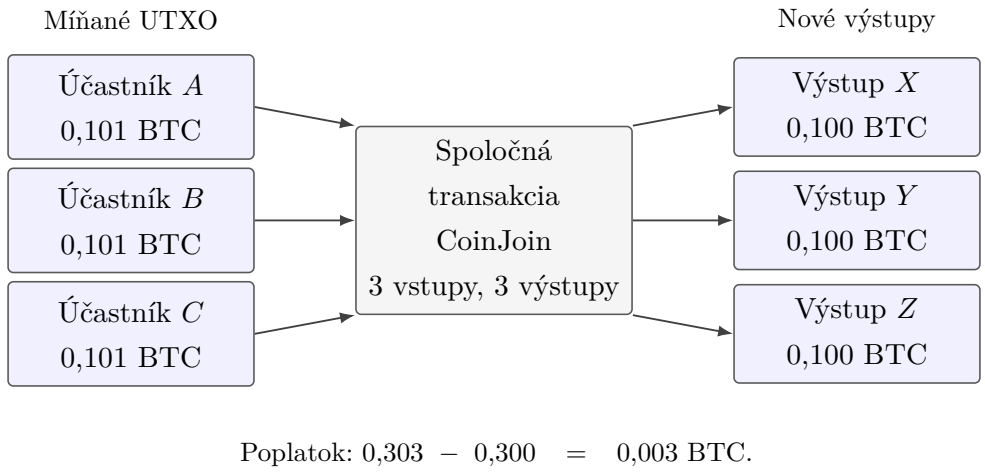


Obr. 6: Modelový scenár pokusu o zakrytie pôvodu prostriedkov. Transakcie P_i míňajú oddelené výstupy transakcií T_i; transakcia K následne spotrebuje ich výstupy a vytvorí jeden výstup pre adresu a. Všetky šípky označujú závislosti minutia. *peeling chain* podľa [7].

Miešacie služby, označované aj ako *mixéry* alebo *tumblery*, sťažujú priradenie vkladu ku konkrétnej následnej výplate. Pri mixéri s úschovou používateľ prevedie prostriedky pod kontrolu prevádzkovateľa, ktorý zabezpečí výplatu na určené adresy z prostriedkov služby. Ruffing a spoluautori [8] upozorňujú, že takýto model vyžaduje dôveru v prevádzkovateľa: ten môže poznať väzby medzi vkladmi a výplatami alebo si prostriedky ponechať. Transakčné záznamy pritom zostávajú v blockchaine.

Konkrétnym prípadom zneužitia mixéra bola služba Helix. Ministerstvo spravodlivosti USA [9] uvádza, že v rokoch 2014 až 2017 spracovala približne 354 000 BTC, pričom značná časť prostriedkov smerovala z nelegálnych trhovísk alebo na ne. Jej prevádzkovateľ sa v roku 2021 priznal k účasti na praní špinavých peňazí.

Od tohto modelu sa odlišuje *CoinJoin*, pri ktorom viacerí účastníci zostavia jednu transakciu s vlastnými vstupmi a dohodnutými výstupmi.



Obr. 7: Zjednodušený príklad CoinJoin s tromi účastníkmi. Šípky znázorňujú spotrebovanie UTXO a vznik výstupov, nie jednoznačné platby $A \to X$, $B \to Y$, $C \to Z$. [8, 10].

Ďalším mechanizmom ochrany súkromia je *CoinSwap*, pri ktorom si účastníci vymieňajú kontrolu nad bitcoinovými výstupmi pomocou vzájomne podmienených transakcií. Vývojová dokumentácia projektu Teleport Transactions [11] opisuje princíp takejto výmeny v rámci Bitcoinu. Ide o odlišný mechanizmus od spoločnej transakcie CoinJoin.

Používanie týchto nástrojov neposkytuje záruku anonymity. Stütz a spoluautori [10] ukázali, že analýza transakcií pred miešaním a po ňom môže zúžiť množinu možných priradení. CoinJoin zároveň slúži aj na ochranu finančného súkromia. FATF preto zdôrazňuje potrebu hodnotiť rizikové indikátory v kontexte. [6].

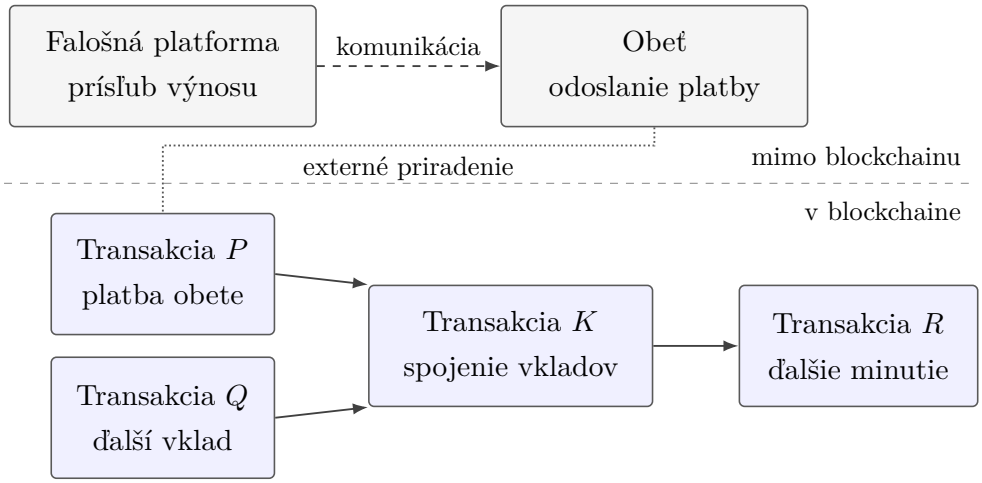
1.8 Podvody a ďalšie zdroje nelegálnych výnosov

Podvodné konanie sa často odohráva mimo blockchainu, hoci jeho finančné dôsledky možno sledovať v transakčnom grafe. Pri falošných investičných platformách páchatelia presviedčajú obete, aby vložili bitcoiny, a v používateľskom rozhraní zobrazujú neexistujúce výnosy. FBI [12] opisuje aj počiatočné povolenie menších výberov na získanie dôvery a neskoršie požiadavky na ďalšie platby pod zámienkou uvoľnenia prostriedkov.

Osobitným prípadom investičného podvodu je *Ponziho schéma*. Organizátori vyplácajú skorších účastníkov z vkladov nových účastníkov namiesto výnosov zo skutočnej investičnej činnosti. Časť obetí tak môže prijímať platby z tej istej schémy, do ktorej predtým vložila prostriedky. Bartoletti a spoluautori [13] skúmali takéto schémy v bitcoinovom blockchaine a využili charakteristiky ich transakcií na klasifikáciu súvisiacich adries.

Pri *phishingu* páchatelia napodobňujú dôveryhodnú službu, aby získali prístupové údaje alebo podnietili obeť k platbe. Falošná technická podpora môže požadovať súkromný kľúč alebo obnovovaciu frázu, z ktorej peňaženka odvodzuje kľúče. Útočník so získanými kľúčmi môže vytvoriť platný podpis a previesť dostupné prostriedky. [3, 14].

Ďalším zdrojom nelegálnych výnosov je *ransomvér*, pri ktorom útočníci požadujú výkupné, napríklad za obnovenie prístupu k zašifrovaným údajom. Ide o vydieranie, ktoré sa od investičného podvodu odlišuje spôsobom získania platby. Europol tieto aktivity uvádza medzi zdrojmi výnosov následne presúvaných prostredníctvom kryptomien [5].



Obr. 8: Analytik môže sledovať prijaté platby, ich spájanie a následné minutie výstupov, z týchto väzieb však priamo nevyčíta obsah komunikácie s obeťou. Opis postupu podvodu vyžaduje aj dôkazy mimo blockchainu, napríklad záznam komunikácie alebo údaje zaistenej platformy.[12, 13].

1.9 Verejné údaje a hranice ich interpretácie

Z verejných záznamov možno zistiť odkazy medzi transakciami, hodnoty výstupov, ich skripty a zaradenie do blokov. Na ich sprístupnenie slúžia prieskumníky blockchainu a indexovacie nástroje. Napríklad Blockbook poskytuje rozhranie API na vyhľadávanie transakcií, blokov a údajov o adresách [15].

Časové údaje je potrebné interpretovať podľa ich pôvodu. Výška bloku vyjadruje jeho poradie v konkrétnom reťazci. Časovú značku v hlavičke určuje ťažiar v medziach pravidiel protokolu a vzťahuje sa na blok ako celok. [3].

Bitcoin poskytuje pseudonymné záznamy. Meiklejohn a spoluautori [16] ukazujú, ako možno transakčné väzby a externé informácie využiť na zoskupovanie adries a priraďovanie služieb. Takto odvodené priradenie adresy ku konkrétnemu subjektu závisí od použitých predpokladov a kvality externých údajov.

2 Dátový súbor Elliptic a jeho využitie pri klasifikácii transakcií

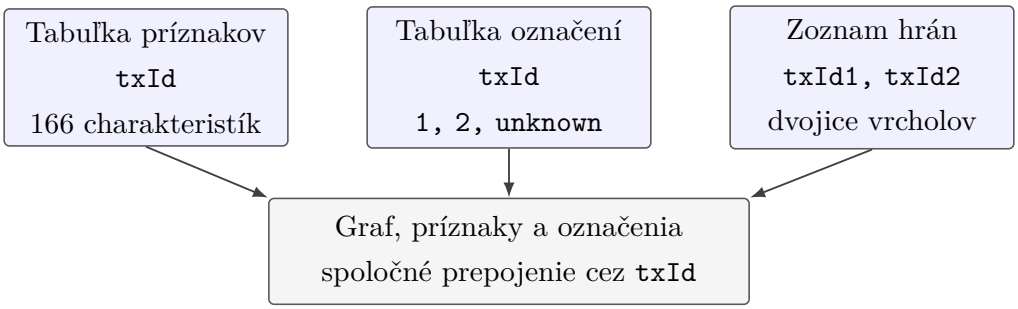
Elliptic Bitcoin Dataset poskytuje verejný podklad na výskum klasifikácie bitcoinových transakcií. Weber a spoluautori [17] ho zverejnili v roku 2019 pre výskum opatrení proti praniu špinavých peňazí, označovaných skratkou AML z anglického *anti-money laundering*. Transakcie opísali číselnými charakteristikami a pre časť záznamov sprístupnili označenie triedy. Takto pripravené údaje umožňujú skúmať vzťah medzi pozorovateľnými vlastnosťami transakcie a jej zaradením do triedy *licit* alebo *illicit*.

Pre vytvorenie programu, ktorý vyhodnotí transakciu podľa jej verejného identifikátora, treba poznať pôvod záznamov a spôsob výpočtu ich charakteristík. Výskum Šafářa a spoluautorov [18] objasnil význam väčšiny príznakov Elliptic a možnosti prepojenia s blockchainom. Tieto poznatky tvoria východisko pre návrh vlastného dátového súboru s overiteľnými transakciami a zdokumentovanými príznakmi.

2.1 Pôvod, štruktúra a označenia transakcií

Elliptic spája graf transakcií s dvoma tabuľkami. Súbor `elliptic_txs_features.csv` priraďuje každej transakcii interný identifikátor `txId` a 166 príznakov. *Príznak* predstavuje číselnú charakteristiku, napríklad počet vstupov alebo poplatok.

Súbor `elliptic_txs_edgelist.csv` obsahuje dvojice identifikátorov spojených orientovanou hranou. Hrana vedie od transakcie, ktorá vytvorila výstup, k transakcii, ktorá ho míňa. Súbor `elliptic_txs_classes.csv` priraďuje identifikátorom označenia `1`, `2` alebo `unknown`. Obrázok 9 znázorňuje spojenie týchto údajov prostredníctvom spoločného identifikátora.



Obr. 9: Prepojenie troch vstupných súborov Elliptic. Identifikátor `txId` slúži na spojenie riadkov tabuliek s vrcholmi grafu. [19].

Označenie `1` zodpovedá triede *illicit*, označenie `2` triede *licit*. Pôvodní autori odvodili triedy z kategórie entity iniciujúcej transakciu. Medzi licitné kategórie zaradili napríklad

burzy a poskytovateľov peňaženiek; medzi ilicitné podvody, ransomvér a Ponziho schémy. Hodnota `unknown` označuje záznam, pre ktorý autori triedu nezverejnili [17].

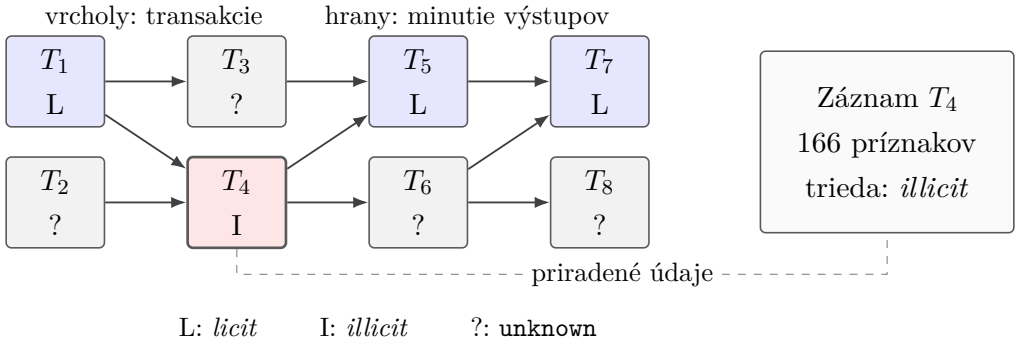
Tabuľka 1: Základná štruktúra pôvodného dátového súboru Elliptic [17].

Položka	Počet
transakcie	203 769
orientované hrany	234 355
príznaky vrátane časového kroku	166
časové kroky	49
označené transakcie	46 564
trieda *licit*	42 019
trieda *illicit*	4 545
neoznačené transakcie	157 205

V navrhovanom riešení budú základom učenia záznamy s označením *licit* alebo *illicit*. Na učenie a vyhodnotenie klasifikácie `unknown` zostáva 46 564 označených transakcií, z ktorých približne 9,76 % patrí do triedy *illicit*. Neoznačené transakcie môžu zostať súčasťou skúmaného grafového okolia; pri učení sa však použijú iba dostupné cieľové triedy. Tým sa zachová rozdiel medzi chýbajúcim označením a licitným záznamom.

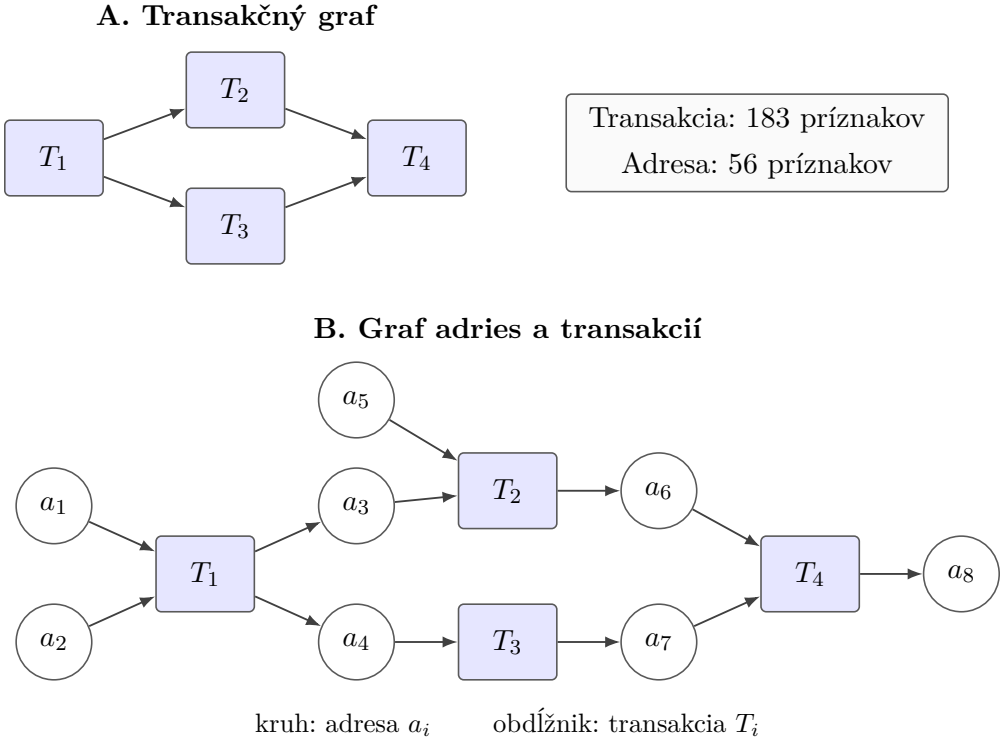
2.2 Rozšírenia dátového súboru Elliptic

Rozšírenia Elliptic sa líšia rozsahom aj jednotkou klasifikácie. Obrázky 10–12 porovnávajú ich grafové reprezentácie na modelových príkladoch s ilustračnými identifikátormi a označeniami. V pôvodnom súbore sa klasifikuje jednotlivá transakcia.



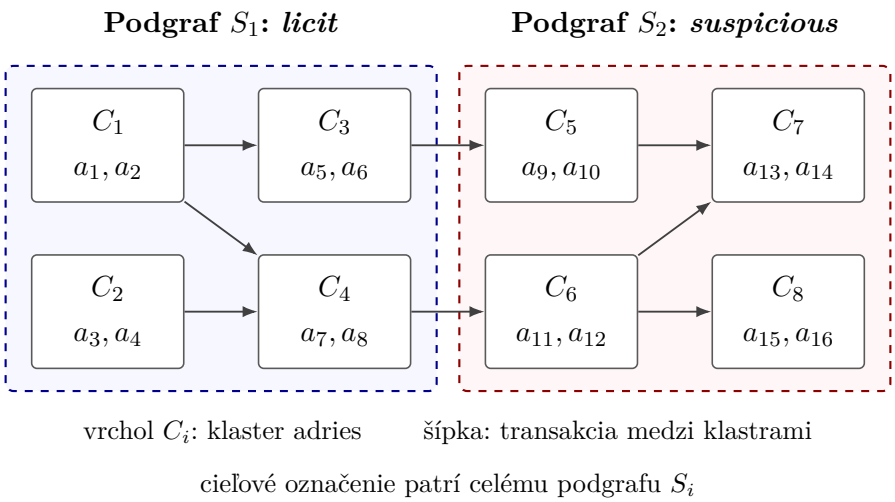
Obr. 10: Pôvodný Elliptic: vrcholy predstavujú transakcie s príznakmi a označeniami. Šípky vyjadrujú míňanie výstupov, čiarkovaná čiara pripojený opis záznamu. Vlastné spracovanie podľa [17].

Elmougy a Liu [20] vytvorili *Elliptic++*, ktorý zachováva pôvodný súbor transakcií a rozširuje ich opis zo 166 na 183 príznakov. Pridali aj údaje o 822 942 adresách s 56 adresnými príznakmi a väzby medzi adresami a transakciami. Výskumníci tak môžu skúmať transakčný aj adresný pohľad na pohyb prostriedkov. Obrázok 11 prepája transakčný graf s pohľadom, v ktorom sú adresy samostatnými vrcholmi. Rovnaké označenia T_i v oboch častiach predstavujú tie isté transakcie.



Obr. 11: Dva prepojené pohľady v Elliptic++ na rovnaký modelový príklad. Hore sú väzby medzi transakciami, dole aj adresy zapojené do ich vstupov a výstupov. Šípka $a_i \to T_j$ označuje vstupnú adresu, šípka $T_j \to a_i$ výstupnú adresu. Transakcia T_4 tak nadväzuje na T_2 a T_3 prostredníctvom adries a_6 a a_7. Vlastné spracovanie podľa [20].

Bellei a spoluautori [21] predstavili *Elliptic2*, v ktorom vrcholy zastupujú klastre adries a hrany transakcie medzi nimi. Autori označili približne 122 tisíc podgrafov triedami *licit* a *suspicious*. Úloha sa preto presúva od posúdenia jednotlivého vrcholu k posúdeniu skupiny previazaných prevodov (obrázok 12). Klastre združujú adresy s predpokladaným spoločným ovládaním; ich vytvorenie vychádza z heuristík a ďalších analytických podkladov.



Obr. 12: Podgrafy ako jednotky klasifikácie v Elliptic2. Každý vrchol zastupuje klaster adries, nie samostatnú transakciu. Rámce vyznačujú dva označené podgrafy v širšom grafe; ich farba vyjadruje triedu podgrafu a neurčuje označenia jednotlivých klastrov. Adresy uvedené vo vrcholoch ilustrujú ich zoskupenie. Vlastné spracovanie podľa [21].

Tabuľka 2: Porovnanie dátových súborov Elliptic podľa ich autorov [17, 20, 21].

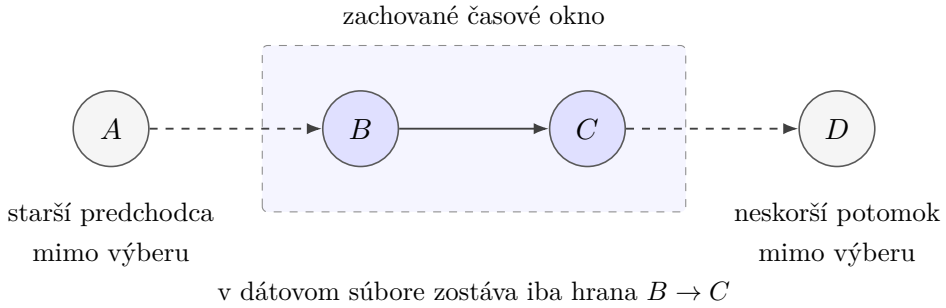
Súbor	Jednotka klasifikácie	Charakteristika
Elliptic	transakcia	203 769 transakcií, 166 príznakov
Elliptic++	transakcia alebo adresa	183 transakčných príznakov, doplnený adresný graf
Elliptic2	podgraf medzi klastrami adries	približne 122 tisíc označených podgrafov

Pre túto prácu zostáva východiskom klasický Elliptic. Jeho transakčné označenia a dostupné prepojenie s verejným blockchainom zodpovedajú zámeru zostaviť vlastnú reprezentáciu jednotlivých transakcií. Rozšírenia poskytujú kontext pre návrh príznakov a grafových okolí; ich odlišné jednotky klasifikácie treba zohľadniť pri prípadnom porovnávaní výsledkov.

2.3 Časový rozsah a transakčný graf

Elliptic pokrýva obdobie od 1. januára 2016 do 2. októbra 2017 prostredníctvom 49 časových podgrafov. Časové kroky sú od seba vzdialené približne dva týždne, pričom transakcie jedného kroku pochádzajú z intervalu kratšieho než tri hodiny. Autori tak zachytili krátke úseky aktivity v rôznych obdobiach. Medzi jednotlivými krokmi v zverejnenom grafe chýbajú hrany [17, 18].

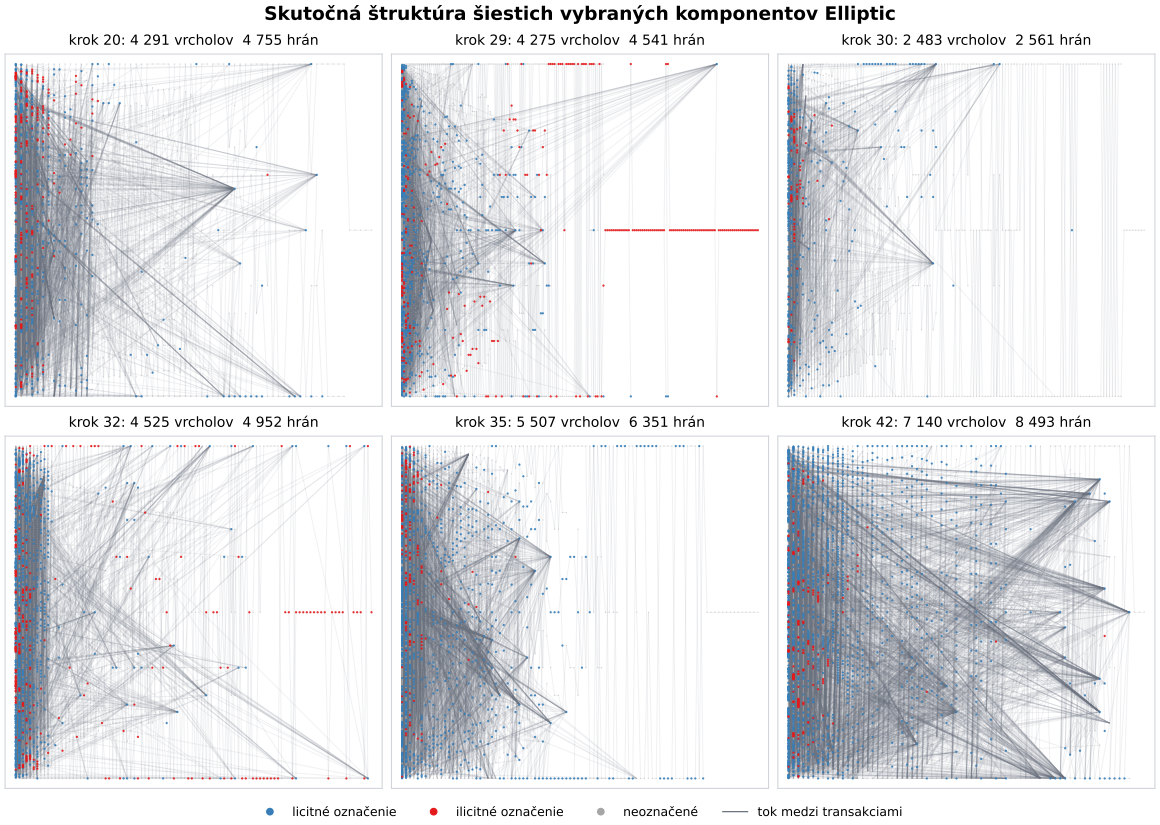
Časový výber obmedzuje dostupné okolie transakcie. Jej predchodca môže ležať mimo zachovaného intervalu, hoci jeho výstup skúmaná transakcia míňa. V uloženom grafe potom chýba príslušný vrchol aj hrana. Obrázok 13 ukazuje tento prípad na dvojici zachovaných transakcií B a C.



Obr. 13: Orezanie transakčného okolia časovým výberom. Čiarkované väzby existujú v blockchaine, ale pri vynechaní vrcholov A a D sa do podgrafu neuložia. Vrchol B preto nemá uloženého predchodcu. Vlastné spracovanie podľa [18].

Pri získavaní údajov z blockchainu možno dohľadať aj predchodcov mimo výberu Elliptic. Rozsah takto obnoveného okolia ovplyvní výpočet grafových príznakov. Počet hrán v dodanom súbore treba preto interpretovať vzhľadom na hranice výberu: nulový vstupný stupeň označuje absenciu uloženého predchodcu a môže sa vyskytnúť aj pri bežnej transakcii.

Obrázok 14 poskytuje ilustráciu šiestich časových krokov pôvodného súboru. Zobrazuje 28 221 transakcií a 31 653 hrán; tento výber slúži na ukážku štruktúry grafu. Vodorovné usporiadanie rešpektuje topologické vrstvy a zvislá poloha rozmiestňuje vrcholy v rámci obrázka. Farba vyjadruje označenie Elliptic; sivé vrcholy sú neoznačené.

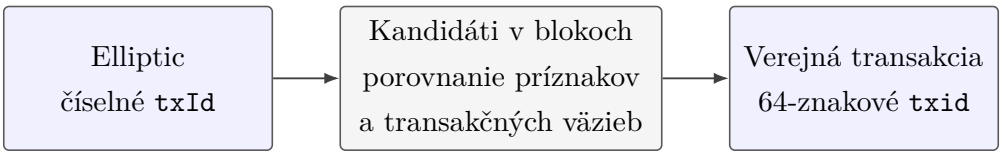


Obr. 14: Transakčné podgrafy časových krokov 20, 29, 30, 32, 35 a 42. Body a spojenia predstavujú skutočné záznamy a hrany. Vlastné spracovanie z pôvodných súborov Elliptic.

2.4 Prepojenie záznamov s verejným blockchainom

Interný identifikátor `txId` spája záznamy v súboroch Elliptic. Verejný bitcoinový identifikátor `txid` má podobu 64 hexadecimálnych znakov a umožňuje vyhľadať konkrétnu transakciu v blockchaine. Na prechod medzi nimi treba vytvoriť alebo overiť mapovanie.

Alex Benzik zverejnil mapovanie približne 99,5 % transakcií Elliptic [22]. Šafář a spoluautori ho použili ako východisko svojho auditu. Pre známe dvojice získali údaje cez Blockbook a porovnali vypočítané charakteristiky s číselnými stĺpcami Elliptic. Takto overovali význam príznakov aj ich väzbu na verejné záznamy [18].



Obr. 15: Mapovanie identifikátorov Elliptic na verejné transakcie. Porovnanie údajov a transakčných väzieb umožňuje overiť zhodu medzi interným záznamom a verejnou transakciou. Vlastné spracovanie podľa [18].

Číselné stĺpce okrem časového kroku majú približne nulový priemer a jednotkovú smerodajnú odchýlku. Autori túto vlastnosť interpretovali ako výsledok štandardizácie pomocou z-skóre:

$$z_{ik} = \frac{x_{ik} - \mu_k}{\sigma_k}, \qquad \sigma_k > 0, \tag{3}$$

kde x_{ik} označuje pôvodnú hodnotu príznaku k pri transakcii i, μ_k priemer stĺpca a σ_k jeho smerodajnú odchýlku. Po odhade parametrov možno hodnotu previesť späť vzťahom $x_{ik} = \mu_k + \sigma_k z_{ik}$. Pri celočíselných počtoch autori využili odstupy medzi hodnotami a pri koreláciách známe ohraničenie ich rozsahu.

Zo známych transakcií následne odvodili kandidátske bloky pre každý časový krok. V týchto blokoch prešli transakcie, vypočítali obnovené príznaky vrátane adresných štatistík k bloku 575 059 a porovnali ich s denormalizovanými záznamami. Pri kolíziách rovnakých vektorov priradili identifikátory podľa pôvodného usporiadania záznamov. Takéto prípady vyžadujú odlíšenie od zhôd, pri ktorých charakteristiky určujú jediného kandidáta.

Autori uvádzajú, že identifikovali všetky transakcie a pri spätnom výpočte dosiahli zhodu všetkých obnovených príznakov. Úplné mapovanie nezverejnili; v diskusii to odôvodňujú svojím výkladom licenčných podmienok Elliptic. Výsledky ich analýzy poskytujú podklad na overovanie zhôd a rekonštrukciu údajov vo vlastnom riešení.

2.5 Príznaky transakcií a možnosti ich rozšírenia

Pôvodný Elliptic obsahuje 94 príznakov označených ako lokálne a 72 agregovaných príznakov susedných transakcií. Šafář a spoluautori zistili, že lokálna skupina zahŕňa aj súhrny histórie vstupných a výstupných adries. Obnovili význam 151 zo 166 príznakov a ich definície zdokumentovali v sprievodnom repozitári [23]. Tabuľka 3 rozlišuje zdroje týchto údajov.

Tabuľka 3: Skupiny príznakov a rozsah obnovenej sémantiky podľa auditu [18, 23]. Číslovanie nezahŕňa stĺpec `txId`.

Rozsah	Zdroj informácie a príklady	Obnovené
1–22	časový krok, poplatok, počty a hodnoty vstupov a výstupov	19 z 22
23–94	prijatá a odoslaná hodnota, zostatok, počet transakcií a životnosť adries	72 zo 72
95–166	hodnoty, bloky, poplatky a počty vstupov a výstupov susedných transakcií	60 zo 72
spolu		151 zo 166

Pri opise transakcií vychádzame z počtov vstupov a výstupov, ich hodnôt a poplatku vypočítaného podľa vzťahu (1). Medzi obnovené príznaky patria minimum, maximum, priemer a smerodajná odchýlka hodnôt. Pearsonov a Spearmanov koeficient vyjadrujú vzťah hodnôt k pozičným indexom vstupov alebo výstupov, čím zachytávajú ich usporiadanie v transakcii. Význam stĺpcov 4, 8 a 16 zostáva neurčený.

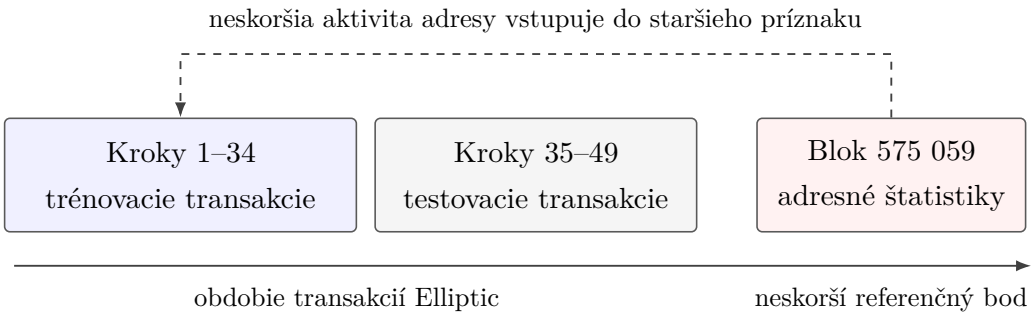
Adresné charakteristiky zahŕňajú históriu adries zapojených do transakcie. Autori identifikovali celkovú prijatú a odoslanú hodnotu, dostupný zostatok, počty prichádzajúcich a odchádzajúcich transakcií a životnosť adresy. Každú z týchto vlastností agregujú pre vstupné a výstupné adresy pomocou minima, maxima, smerodajnej odchýlky, priemeru a Pearsonovho a Spearmanovho koeficientu. Táto skupina obsahuje 72 príznakov.

Pri susedných transakciách autori obnovili súhrny objemu, výšky bloku, poplatku a počtov vstupov a výstupov. Počítajú ich osobitne pre predchodcov a nasledovníkov, pričom do výpočtu zahŕňajú aj transakcie mimo uloženého grafu Elliptic. Význam ďalších dvanástich príznakov v rozsahoch 113–118 a 149–154 zostáva neurčený.

V tejto práci navrhujeme rozšíriť uvedené skupiny o príznaky odvodené z verejných blockchainových údajov. Ako kandidátov na zaradenie do vlastného dátového súboru volíme vek míňaných výstupov, podiel najväčšieho výstupu na celkovej výstupnej hodnote a počet predchádzajúcich transakcií zapojených adries. Vek výstupov vyjadríme počtom blokov medzi ich vytvorením a minutím. Týmito príznakmi chceme zachytiť dobu držania prostriedkov, rozdelenie prevádzanej hodnoty a predchádzajúcu aktivitu adries.

2.6 Obmedzenia dátového súboru

Audit Šafářa a spoluautorov [18] odhalil, že adresné štatistiky Elliptic zodpovedajú jedinému referenčnému bloku 575 059. Tento blok nasledoval až po období zobrazených transakcií. Staršie záznamy tak obsahujú aj informácie o neskoršej aktivite adries, ako znázorňuje obrázok 16. Vo vlastnom riešení preto použijeme iba históriu dostupnú v zvolenom okamihu vyhodnotenia transakcie.



Obr. 16: Časový únik pri spoločnom referenčnom bloku. Transakcie sú časovo oddelené, ale ich adresné príznaky vychádzajú z neskoršej histórie. Schéma vyjadruje časové poradie udalostí. Vlastné spracovanie podľa [18].

Pri návrhu programu určíme, či budeme transakciu vyhodnocovať po potvrdení, alebo pri spätnej analýze s časovým odstupom. Podľa tohto rozhodnutia zvolíme rozsah dostupnej histórie. Informácie o nasledovníkoch zahrnieme do príznakov až vtedy, keď budú príslušné transakcie v sledovanom okamihu známe.

Ďalším obmedzením sú spoločné adresy v rôznych časových krokoch (obrázok 17). Opakované adresné štatistiky môžu modelu pomôcť rozpoznať adresy, ktoré už pozoroval pri učení. Vo vlastných experimentoch budeme sledovať výskyt spoločných adries v trénovacej a testovacej časti aj v pridaných grafových okolách. Tento prekryv zohľadníme pri hodnotení prenosu modelu na dovtedy nepozorované adresy.



spoločná adresa prepája príklady aj bez transakčnej hrany

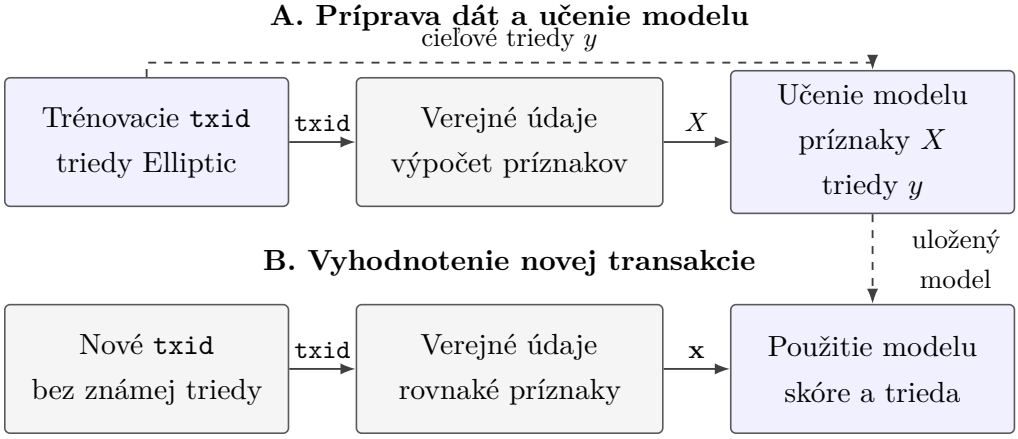
Obr. 17: Prekryv adries medzi tréningom a testom. Úsečky označujú účasť adresy v transakcii. Vlastné spracovanie podľa [18].

Pôvodná štandardizácia navyše používa priemery a smerodajné odchýlky celého dátového súboru. Kaufman a spoluautori aj Kapoor a Narayanan upozorňujú na riziko využívania testovacích údajov pri príprave modelu [24, 25]. Parametre predspracovania odhadneme z trénovacej časti a v nezmenenej podobe ich použijeme pri spracovaní ostatných záznamov. Pri interpretácii výsledkov budeme rozlišovať označenie prevzaté z Elliptic a nezávisle doložený kontext konkrétnej transakcie. Zverejnené súbory totiž neobsahujú podklady, podľa ktorých Elliptic priradil entity k jednotlivým transakciám.

2.7 Východiská vlastného riešenia

Navrhujeme vytvoriť dátový súbor, v ktorom prepojíme označené záznamy Elliptic s overenými bitcoinovými transakciami. Z verejných údajov vypočítame zvolené príznaky a zdokumentujeme ich význam, jednotku, spôsob výpočtu a rozsah použitej histórie. Pôvodnú triedu Elliptic zachováme ako cieľové označenie.

Na pripravených údajoch natrénujeme klasifikačný model. Časť označených transakcií vyhradíme na overenie jeho výsledkov. Obrázok 18 oddeľuje učenie so známymi triedami od použitia modelu na novú transakciu.



Obr. 18: Oddelenie učenia a použitia klasifikačného modelu. Cieľové triedy y vstupujú do učenia; nová transakcia sa vyhodnotí pomocou rovnakého výpočtu príznakov a uloženého modelu. Vlastné spracovanie.

Pre použitie modelu navrhujeme program, do ktorého používateľ zadá verejné `txid`. Program získa potrebné údaje, zopakuje výpočet príznakov a predspracovanie a použije uložený model. Takto budeme vyhodnocovať aj transakcie mimo učebnej vzorky, ak budú dostupné všetky požadované vstupy. Výstupom bude skóre a predikcia triedy; označenie *illicit* budeme interpretovať ako podnet na ďalšie posúdenie.

Záver

Literatúra

1. NAKAMOTO, S. *Bitcoin: A Peer-to-Peer Electronic Cash System* [online]. 2008. [cit. 2026-10-06]. Dostupné z: `https://bitcoin.org/bitcoin.pdf`.
2. BITCOIN.ORG. *Frequently Asked Questions* [online]. [cit. 2026-10-15]. Dostupné z: `https://bitcoin.org/en/faq`.
3. BITCOIN.ORG. *Bitcoin Developer Documentation* [online]. [cit. 2026-10-20]. Dostupné z: `https://developer.bitcoin.org/`. Použité časti: Developer Guide a Developer Reference, najmä témy Block Chain, Transactions, Wallets, Mining a P2P Network.
4. LOMBROZO, E.; LAU, J.; WUILLE, P. *BIP 141: Segregated Witness (Consensus layer)* [online]. [cit. 2026-10-13]. Dostupné z: `https://github.com/bitcoin/bips/blob/master/bip-0141.mediawiki`.
5. EUROPOL. *Cryptocurrencies: Tracing the Evolution of Criminal Finances* [online]. Luxembourg, 2022 [cit. 2026-10-17]. Publications Office of the European Union. Dostupné z: `https://www.europol.europa.eu/publications-events/publications/cryptocurrencies-tracing-evolution-of-criminal-finances`.
6. FINANCIAL ACTION TASK FORCE. *Virtual Assets: Red Flag Indicators of Money Laundering and Terrorist Financing* [online]. Paris, 2020-09 [cit. 2026-10-17]. FATF. Dostupné z: `https://www.fatf-gafi.org/content/dam/fatf-gafi/reports/Virtual-Assets-Red-Flag-Indicators.pdf`.
7. KAPPOS, G. et al. How to Peel a Million: Validating and Expanding Bitcoin Clusters. In: *31st USENIX Security Symposium* [online]. USENIX Association, 2022, s. 2207–2223 [cit. 2026-10-17]. Dostupné z: `https://www.usenix.org/conference/usenixsecurity22/presentation/kappos`.
8. RUFFING, T.; MORENO-SANCHEZ, P.; KATE, A. CoinShuffle: Practical Decentralized Coin Mixing for Bitcoin. In: *Computer Security – ESORICS 2014*. Springer, 2014, zv. 8713, s. 345–364. Lecture Notes in Computer Science. Dostupné z DOI: `10.1007/978-3-319-11212-1_20`.
9. U.S. DEPARTMENT OF JUSTICE. *U.S. Obtains Legal Title to $400 Million in Assets Tied to Helix Cryptocurrency Mixer* [online]. 2026-01-29. [cit. 2026-10-17]. Dostupné z: `https://www.justice.gov/usao-dc/pr/us-obtains-legal-title-400-million-assets-tied-helix-cryptocurrency-mixer`.

10. STÜTZ, R.; STOCKINGER, J.; MORENO-SANCHEZ, P.; HASLHOFER, B.; MAFFEI, M. Adoption and Actual Privacy of Decentralized CoinJoin Implementations in Bitcoin. In: *Proceedings of the 4th ACM Conference on Advances in Financial Technologies*. Association for Computing Machinery, 2022, s. 254–267. Dostupné z DOI: 10.1145/3558535.3559782.

11. BITCOIN TELEPORT. *Teleport Transactions: CoinSwap Implementation* [online]. [cit. 2026-10-17]. Dostupné z: https://github.com/bitcoin-teleport/teleport-transactions.

12. FEDERAL BUREAU OF INVESTIGATION. *Cryptocurrency Investment Fraud* [online]. [cit. 2026-10-17]. Dostupné z: https://www.fbi.gov/how-we-can-help-you/victim-services/national-crimes-and-victim-resources/cryptocurrency-investment-fraud.

13. BARTOLETTI, M.; PES, B.; SERUSI, S. Data Mining for Detecting Bitcoin Ponzi Schemes. In: *2018 Crypto Valley Conference on Blockchain Technology*. IEEE, 2018. Dostupné z arXiv: 1803.00646.

14. BITCOIN.ORG. *Avoid Scams* [online]. [cit. 2026-10-17]. Dostupné z: https://bitcoin.org/en/scams.

15. TREZOR. *Blockbook* [online]. [cit. 2026-10-13]. Dostupné z: https://github.com/trezor/blockbook.

16. MEIKLEJOHN, S. et al. A Fistful of Bitcoins: Characterizing Payments among Men with No Names. *Communications of the ACM*. 2016, **59**(4), 86–93. Dostupné z DOI: 10.1145/2896384.

17. WEBER, M. et al. Anti-Money Laundering in Bitcoin: Experimenting with Graph Convolutional Networks for Financial Forensics. 2019. Dostupné z DOI: 10.48550/arXiv.1908.02591.

18. ŠAFÁŘ, M.; PLUSKAL, J.; VESELÝ, V.; RYŠAVÝ, O. The enemy of reproducibility is opacity: What's inside the Elliptic bitcoin dataset (and why it is wrong). *Forensic Science International: Digital Investigation*. 2026, **57**(1), 302124. Dostupné z DOI: 10.1016/j.fsidi.2026.302124.

19. ELLIPTIC. *Elliptic Data Set* [online]. [cit. 2026-10-06]. Dostupné z: https://www.kaggle.com/datasets/ellipticco/elliptic-data-set.

20. ELMOUGY, Y.; LIU, L. Demystifying Fraudulent Transactions and Illicit Nodes in the Bitcoin Network for Financial Forensics. 2023. Dostupné z DOI: 10.48550/arXiv.2306.06108.

21. BELLEI, C. et al. The Shape of Money Laundering: Subgraph Representation Learning on the Blockchain with the Elliptic2 Dataset. 2024. Dostupné z DOI: 10.48550/arXiv.2404.19109.

22. BENZIK, A. *Deanonymized 99.5 Percent of Elliptic Transactions* [online]. 2019. [cit. 2026-10-11]. Dostupné z: https://www.kaggle.com/datasets/alexbenzik/deanonymized-995-pct-of-elliptic-transactions.

23. ŠAFÁŘ, M.; PLUSKAL, J.; VESELÝ, V.; RYŠAVÝ, O. *Deanonymized Elliptic Transaction Features* [online]. 2026. [cit. 2026-10-11]. Dostupné z: https://github.com/nesfit/DeanonymizedEllipticBitcoinDataset.

24. KAUFMAN, S.; ROSSET, S.; PERLICH, C.; STITELMAN, O. Leakage in Data Mining: Formulation, Detection, and Avoidance. *ACM Transactions on Knowledge Discovery from Data*. 2012, **6**(4). Dostupné z DOI: 10.1145/2382577.2382579.

25. KAPOOR, S.; NARAYANAN, A. Leakage and the Reproducibility Crisis in Machine-Learning-Based Science. *Patterns*. 2023, **4**(9), 100804. Dostupné z DOI: 10.1016/j.patter.2023.100804.