SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-xxxx-xxxx

Blockchain analýza

Bakalárska práca

2026 **Postaichuk Pavlo**

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-xxxx-xxxx

Blockchain analýza

Bakalárska práca

Študijný program:	Aplikovaná informatika
Študijný odbor:	informatika
Školiace pracovisko:	Ústav informatiky a matematiky FEI STU
Školiteľ:	prof. Ing. Pavol Zajac, PhD.

2026 **Postaichuk Pavlo**

Obsah

Úvod **3**

1 Základné pojmy **4**

1.1 Bitcoin a blockchain 4

1.2 Transakcia, výstup a identifikátor 4

1.3 Kľúče, podpis a adresa 5

1.4 Blok, ťažba a dôkaz práce 5

1.5 Konsenzus a dostupnosť transakcií 6

1.6 Verejné údaje, pseudonymita a graf transakcií 6

1.7 Elliptic Bitcoin Dataset 6

2 Prístupy k analýze bitcoinových transakcií **8**

2.1 Získanie a príprava údajov 8

2.2 Sledovanie väzieb a grafová analýza 8

2.3 Klasifikácia transakcií v datasete Elliptic 8

2.4 Párovanie anonymizovaného záznamu s verejnou transakciou 9

Literatúra **10**

Úvod

Blockchainové technológie predstavujú významnú oblasť súčasnej informatiky a finančných technológií. Blockchain možno charakterizovať ako distribuovaný systém, v ktorom sú údaje o transakciách ukladané v chronologicky usporiadaných blokoch. Verejný charakter blockchainu umožňuje používateľom overovať transakcie bez centrálneho správcu, pričom zároveň vytvára rozsiahly zdroj údajov vhodný na analytické spracovanie [1].

Analýza blockchainových transakcií je dôležitá najmä z hľadiska identifikácie podozrivých aktivít, prania špinavých peňazí a ďalších nelegálnych činností. Na tento účel sa využívajú metódy strojového učenia, grafové modely a algoritmy na detekciu anomálií. Transakcie možno reprezentovať ako graf, v ktorom vrcholy predstavujú transakcie a hrany vyjadrujú tok prostriedkov medzi nimi [2].

1 Základné pojmy

Táto kapitola vysvetľuje pojmy potrebné pri práci s verejnými údajmi o bitcoinových transakciách. Najprv opisuje spôsob, akým Bitcoin zaznamenáva a overuje transakcie, a potom rozlišuje údaje vo verejnom blockchaine od identifikátorov použitých vo výskumnom datasete.

1.1 Bitcoin a blockchain

Bitcoin je systém elektronických platieb, v ktorom účastníci prenášajú transakcie prostredníctvom siete bez centrálnej autority spravujúcej spoločnú účtovnú knihu. Jednotlivé uzly uchovávajú a overujú údaje podľa pravidiel protokolu. Nakamoto navrhol reťazec blokov zabezpečený dôkazom práce ako spôsob určenia poradia transakcií a riešenia problému opakovaného minutia tých istých prostriedkov [1].

Blockchain Bitcoinu je postupnosť blokov. Každý blok obsahuje hlavičku a transakcie; v hlavičke je uložený hash hlavičky predchádzajúceho bloku. Táto väzba spája bloky do reťazca. Hlavička obsahuje aj koreň Merkleovho stromu zostaveného z transakcií daného bloku. Zmena niektorej z nich by preto zmenila aj hodnotu koreňa a následne hash hlavičky bloku [3].

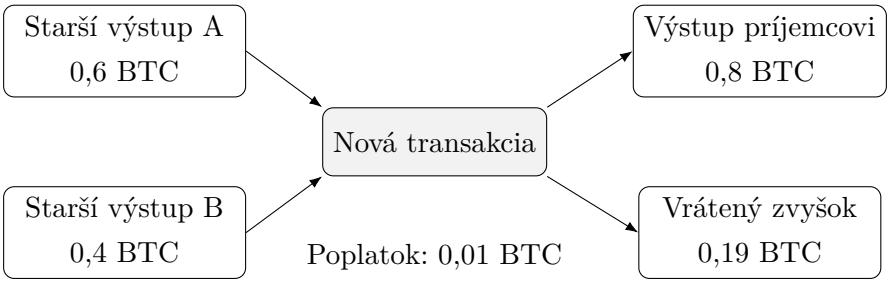
1.2 Transakcia, výstup a identifikátor

Bežná bitcoinová transakcia má vstupy a výstupy. Vstup odkazuje na konkrétny výstup skoršej transakcie a poskytuje údaje potrebné na splnenie podmienok jeho minutia. Výstup určuje hodnotu v satoshi a podmienky, za ktorých možno túto hodnotu neskôr minúť. Výstup, ktorý zatiaľ žiadna transakcia neminula, sa označuje ako *unspent transaction output* (UTXO). Výnimkou je prvá, tzv. coinbase transakcia v bloku, ktorá nemá bežné vstupy odkazujúce na staršie výstupy [4, 5].

Identifikátor transakcie (`txid`) umožňuje odkazovať na konkrétnu bitcoinovú transakciu. Na určenie jej výstupu sa spolu s identifikátorom používa index výstupu. Toto rozlíšenie je podstatné pri rekonštrukcii toku prostriedkov: nasledujúca transakcia odkazuje na výstup predchádzajúcej transakcie, nie iba na adresu účastníka [4].

V bežnej transakcii sa súčet hodnôt vstupov rovná súčtu hodnôt výstupov a transakčného poplatku. Ak vlastník minie výstup s vyššou hodnotou, než chce previesť príjemcovi, môže vytvoriť ďalší výstup na vrátenie zvyšku hodnoty, označovaný ako *výstup na vrátenie zvyšku* (change output). Tento výstup je z pohľadu protokolu obyčajný výstup; na určenie jeho vlastníka nestačí iba jeho pozícia v transakcii [4].

Obrázok 1 ukazuje zjednodušený príklad. Hodnoty sú ilustračné a nepochádzajú zo skutočnej transakcie. Výstupy starších transakcií tvoria vstupy novej transakcie; poplatok nevzniká ako samostatný výstup, ale ako rozdiel súčtov.



Obr. 1: Príklad použitia dvoch výstupov ako vstupov ďalšej transakcie. Vlastné spracovanie podľa [4].

1.3 Kľúče, podpis a adresa

Súkromný kľúč slúži na vytvorenie digitálneho podpisu pri autorizácii minutia príslušného výstupu. Z neho sa odvodzuje *verejný kľúč*, pomocou ktorého možno podpis overiť bez znalosti súkromného kľúča. Podpis teda poskytuje dôkaz o splnení podmienky minutia výstupu; sám osebe neprezrádza občiansku identitu osoby, ktorá transakciu vytvorila [4].

Bitcoinová adresa je používateľský zápis údajov potrebných na vytvorenie určitého typu výstupu. Nie je totožná so súkromným kľúčom, identifikátorom transakcie ani s jednoznačnou identitou používateľa. Jedna peňaženka môže spravovať viacero kľúčov a adries. Pri analýze preto nemožno bez ďalších údajov považovať dve rôzne adresy za dvoch rôznych ľudí ani jednu adresu za úplný opis peňaženky [4, 6].

1.4 Blok, ťažba a dôkaz práce

Ťažiar pripraví kandidátsky blok z transakcií, ktoré má k dispozícii. Prvou transakciou v bloku je coinbase transakcia. Jej výstupy môžu obsahovať novo vytvorené bitcoiny podľa pravidiel aktuálnej výšky bloku aj poplatky za zahrnuté transakcie. Výška odmeny sa v čase mení, preto ju nemožno uvádzať ako stálu vlastnosť systému [5].

Pri *dôkaze práce* (proof of work) ťažiar hľadá takú hlavičku bloku, ktorej dvojitý hash SHA-256 nepresiahne stanovený cieľ. Skúša rôzne hodnoty poľa `nonce`; po vyčerpaní jeho možností môže zmeniť aj ďalšie údaje ovplyvňujúce hlavičku. Nájsť vyhovujúci hash vyžaduje opakované pokusy, zatiaľ čo jeho overenie je jednoduché [3, 7].

Protokol upravuje náročnosť dôkazu práce tak, aby medzi blokmi uplynulo v dlhodobom priemere približne desať minút. Nejde o pevný interval: jednotlivé bloky môžu

vzniknúť rýchlejšie alebo pomalšie. Po nájdení vyhovujúceho bloku ho ťažiar rozpošle sieti. Úplné uzly kontrolujú, či blok aj jeho transakcie spĺňajú pravidlá protokolu [5, 7].

1.5 Konsenzus a dostupnosť transakcií

Konsenzus v Bitcoine označuje stav, keď uzly pracujú s rovnakým lokálne overeným reťazcom blokov. *Pravidlá konsenzu* určujú, ktoré bloky a transakcie môžu uzly prijať. Dôkaz práce pomáha uzlom vybrať platný reťazec s najväčším nahromadeným množstvom práce; samotné splnenie cieľa hashovania nestačí, ak blok porušuje pravidlá validácie [5, 8].

Transakcia, ktorá ešte nie je v bloku, môže byť uložená v pamäťovej zásobe nepotvrdených transakcií konkrétneho uzla, označovanej ako *mempool*. Mempool nie je súčasťou blockchainu a rôzne uzly nemusia mať v danom okamihu rovnaký obsah tejto zásoby. Pri analýze údajov preto treba odlišovať nepotvrdenú transakciu od transakcie zaznamenanej v bloku [9].

1.6 Verejné údaje, pseudonymita a graf transakcií

Z verejného blockchainu možno získať napríklad identifikátory potvrdených transakcií, ich vstupy a výstupy, hodnoty výstupov a bloky, do ktorých boli transakcie zaradené. Tieto údaje neobsahujú všeobecne platný zoznam mien vlastníkov adries. Bitcoin sa preto pri analýze označuje ako *pseudonymný*: pozorovateľ vidí tok medzi transakciami, no priradenie adries ku konkrétnym osobám vyžaduje ďalšie informácie alebo predpoklady [10].

Graf transakcií predstavuje transakcie vrcholmi a väzby medzi nimi orientovanými hranami. Hrana vedie od staršej transakcie k novšej vtedy, keď vstup novšej míňa výstup staršej. Takýto graf sa líši od *grafu adries*, v ktorom vrcholy predstavujú adresy. Voľba reprezentácie určuje, čo možno v grafe priamo pozorovať: väzbu medzi transakciami možno odvodiť z odkazov na výstupy, zatiaľ čo vzťah medzi adresami alebo vlastníctvom môže vyžadovať heuristiky [4, 10].

Zhlukovanie adries spája adresy, o ktorých analytik predpokladá spoločného vlastníka. Napríklad použitie viacerých vstupov v jednej transakcii môže byť indíciou spoločnej kontroly, no nejde o dôkaz totožnosti používateľa. Výsledky zhlukovania preto treba uvádzať spolu s použitou heuristikou a jej obmedzeniami [10].

1.7 Elliptic Bitcoin Dataset

Elliptic Bitcoin Dataset predstavuje bitcoinové transakcie ako vrcholy grafu a toky medzi transakciami ako orientované hrany. Autori zverejnili viac ako 200-tisíc transakcií,

približne 234-tisíc hrán a 166 príznakov pri každom vrchole. Časť vrcholov má označenie *licitná* alebo *ilicitná* transakcia, ostatné sú neoznačené. Dataset zahŕňa 49 časových krokov; autori použili tieto údaje na porovnanie klasifikačných metód vrátane Random Forest a grafových neurónových sietí [2].

Identifikátory vrcholov v zverejnenom anonymizovanom datasete treba odlišovať od verejných bitcoinových `txid`. Bez osobitne overeného mapovania nemožno z hodnoty identifikátora v datasete vyvodiť hash pôvodnej transakcie ani ju priamo vyhľadať vo verejnom prehliadači blockchainu [2, 11].

Novšia analýza poukázala na nejasnú sémantiku príznakov Elliptic a na riziko úniku informácie medzi používanými trénovacími a testovacími časťami datasetu. Pri návrhu experimentu preto bude potrebné uviesť pôvod použitých príznakov a presne opísať rozdelenie dát. Otázku, či možno konkrétny záznam datasetu priradiť k verejnej bitcoinovej transakcii, nemožno rozhodnúť iba porovnaním jeho anonymizovaného identifikátora s `txid` [12].

2 Prístupy k analýze bitcoinových transakcií

Táto kapitola porovnáva postupy, ktoré možno použiť pri skúmaní bitcoinových transakcií. Výber konkrétnej výskumnej otázky a metódy ostáva otvorený; nasledujúce podkapitoly uvádzajú, aké údaje by jednotlivé postupy potrebovali a aké tvrdenia by z nich bolo možné odôvodniť.

2.1 Získanie a príprava údajov

Zdrojom verejných údajov je bitcoinový blockchain. Záznam o transakcii obsahuje odkazy na minuté výstupy, nové výstupy a ďalšie údaje potrebné na jej overenie. Analytik môže získať údaje z vlastného uzla alebo z externého rozhrania, ktoré sprístupňuje údaje uzla. Pri použití externého rozhrania treba zaznamenať, odkiaľ údaje pochádzajú, kedy boli získané a ktoré polia boli dostupné; bez toho sa experiment ťažko zopakuje [4, 5].

Pri spracovaní je potrebné odlišovať identifikátor transakcie od identifikátora jej výstupu, teda dvojice `txid` a indexu výstupu. Rovnako treba určiť, či vzorka zahŕňa iba potvrdené transakcie. Čas uvedený v hlavičke bloku nie je presným časom, keď používateľ vytvoril alebo prvýkrát odoslal každú transakciu v bloku [3, 4].

2.2 Sledovanie väzieb a grafová analýza

Najpriamejšou väzbou medzi dvoma potvrdenými transakciami je odkaz vstupu na skorší výstup. Z týchto odkazov možno zostaviť orientovaný graf a skúmať napríklad postupnosť nadväzujúcich transakcií alebo veľkosť zvoleného podgrafu. Samotná existencia hrany však neurčuje, ktorá osoba ovláda oba konce väzby. Pri transakcii s viacerými vstupmi a výstupmi navyše nemožno bez doplnkovej metodiky jednoznačne priradiť každý vstup ku konkrétnemu výstupu [4].

Na prechod od grafu transakcií ku grafu predpokladaných vlastníkov sa používajú heuristiky. Meiklejohn a spoluautori ukázali, že zhlukovanie adries a externé informácie môžu pomôcť identifikovať časti bitcoinovej ekonomiky. Takéto závery závisia od predpokladov o spoločnej kontrole adries; v práci preto treba oddeliť pozorovanú väzbu v blockchaine od odhadovaného vlastníctva [10].

2.3 Klasifikácia transakcií v datasete Elliptic

Elliptic umožňuje skúmať inú úlohu: predikovať označenie transakcie z príznakov a zo štruktúry grafu. Autori datasetu porovnali metódy, ktoré využívajú príznaky jednotlivých transakcií, s grafovými modelmi, ktoré spracúvajú aj informáciu o susedných vrcholoch. Pre vyhodnotenie je dôležitá triedna nevyváženosť: ilicitne označených trans-

akcií je podstatne menej než licitne označených. Z tohto dôvodu samotná celková úspešnosť nemusí vystihovať schopnosť zachytiť ilicitnú triedu; vhodné je uvádzať precíznosť (precision), úplnosť (recall) a mieru F_1 pre túto triedu [2].

Pri porovnávaní modelov treba určiť, ktoré časové kroky patria do tréningovej a testovacej časti. Novšia analýza datasetu upozornila, že aj často používané rozdelenia môžu obsahovať únik informácie. Výsledok modelu preto závisí nielen od algoritmu, ale aj od pôvodu príznakov a od spôsobu rozdelenia dát [12].

2.4 Párovanie anonymizovaného záznamu s verejnou transakciou

Samostatnou výskumnou otázkou môže byť, či sa záznam anonymizovaného datasetu dá priradiť ku konkrétnej verejnej transakcii. Takýto postup by vyžadoval opis príznakov, ktoré možno nezávisle vypočítať z blockchainu, vytvorenie množiny kandidátov a overenie, či výsledné priradenie nie je zameniteľné s inými transakciami. Zhoda niekoľkých číselných príznakov sama osebe nedokazuje totožnosť transakcií. Osobitne treba preveriť, či použitý príznak neobsahuje informáciu, ktorá v čase skúmanej transakcie nebola verejne dostupná. Tento smer je zatiaľ návrhom možného experimentu, nie dosiahnutým výsledkom [2, 12].

Literatúra

1. NAKAMOTO, S. *Bitcoin: A Peer-to-Peer Electronic Cash System* [online]. 2008. [cit. 2026-10-06]. Dostupné z: `https://bitcoin.org/bitcoin.pdf`.
2. WEBER, M. et al. Anti-Money Laundering in Bitcoin: Experimenting with Graph Convolutional Networks for Financial Forensics. 2019. Dostupné z DOI: `10.48550/arXiv.1908.02591`.
3. BITCOIN.ORG. *Bitcoin Developer Reference: Block Chain* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/reference/block_chain.html`.
4. BITCOIN.ORG. *Bitcoin Developer Guide: Transactions* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/devguide/transactions.html`.
5. BITCOIN.ORG. *Bitcoin Developer Guide: Block Chain* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/devguide/block_chain.html`.
6. BITCOIN.ORG. *Bitcoin Developer Guide: Wallets* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/devguide/wallets.html`.
7. BITCOIN.ORG. *Bitcoin Developer Guide: Mining* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/devguide/mining.html`.
8. BITCOIN.ORG. *Bitcoin Developer Glossary* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/glossary.html`.
9. BITCOIN.ORG. *Bitcoin Developer Guide: P2P Network* [online]. [cit. 2026-10-06]. Dostupné z: `https://developer.bitcoin.org/devguide/p2p_network.html`.
10. MEIKLEJOHN, S. et al. A Fistful of Bitcoins: Characterizing Payments among Men with No Names. *Communications of the ACM*. 2016, **59**(4), 86–93. Dostupné z DOI: `10.1145/2896384`.
11. ELLIPTIC. *Elliptic Data Set* [online]. [cit. 2026-10-06]. Dostupné z: `https://www.kaggle.com/datasets/ellipticco/elliptic-data-set`.
12. ŠAFÁŘ, M.; PLUSKAL, J.; VESELÝ, V.; RYŠAVÝ, O. The enemy of reproducibility is opacity: What's inside the Elliptic bitcoin dataset (and why it is wrong). *Forensic Science International: Digital Investigation*. 2026, **57**(1), 302124–302131. Dostupné z DOI: `10.1016/j.fsidi.2026.302124`.